

# Note méthodologique classification d'images produits comparaison ResNet34 et DINOv2

## 1. Contexte et objectif

Dans le cadre du projet de classification automatique d'images de produits e-commerce (7 catégories), nous avons comparé une approche classique (CNN supervisé) à une approche "state of the art" (vision transformer auto-supervisé) pour améliorer la précision et la capacité de généralisation.

## 2. Choix des algorithmes

- **baseline (référence) : ResNet34**
  - **Type** : CNN (Réseau de Neurones Convolutif).
  - **Pré-entraînement** : supervisé sur ImageNet (~1M images labellisées).
  - **Pourquoi** : standard industriel robuste pour la vision par ordinateur, efficace mais parfois limité sur des datasets hétérogènes.
- **challenger (innovation) : DINOv2 (variante vitb14\_reg)**
  - **Type** : vision transformer (ViT) avec registres.
  - **Pré-entraînement** : auto-supervisé (SSL) sur LVD-142M (142M images non labellisées).
  - **Pourquoi** : la méthode SSL combine DINO (apprentissage invariant par vues globales/locales) et iBOT (reconstruction de masques). Cela permet d'apprendre des caractéristiques sémantiques riches sans labels, offrant une meilleure généralisation. Les "registres" corrigent les artefacts visuels des ViT classiques.

## 3. Démarche de modélisation

Pour une comparaison équitable, les deux modèles ont été utilisés en **feature extraction** (backbone gelé) avec une tête de classification identique entraînée sur nos données (840 images train, 210 validation).

- **Architecture de la tête** : dropout (0.5) + couche linéaire.
- **Stratégies d'entraînement différenciées**:
  - **DINOv2**: feature extraction pure (backbone gelé, 25 epochs). Les représentations SSL étant déjà hautement génériques, seule la tête est entraînée.
  - **ResNet34**: entraînement progressif en 2 phases pour adapter les features ImageNet:
    - Phase 1 (3 epochs): Tête + BatchNorm (LR=1e-4)
    - Phase 2 (20 epochs): Tête + BatchNorm + Layer3/4 (LR=1e-5)

### Optimisation commune:

- Loss: CrossEntropyLoss
- Optimiseur: AdamW (LR=1e-4, weight decay=1e-4)
- Scheduler: ReduceLROnPlateau (factor=0.1, patience=5)
- Early Stopping: patience=5 epochs
- Batch size: 32, workers: 8

### Augmentations adaptées:

- **ResNet**: affine (scale/rotate/translate), ColorJitter, GaussNoise/Blur (p=0.3) - augmentation agressive pour compenser la spécialisation ImageNet
- **DINOv2**: colorJitter, HorizontalFlip - augmentation légère suffisante grâce à l'invariance SSL

## 4. Évaluation et résultats comparatifs

La métrique principale retenue est l'**accuracy** (précision globale).

ResNet (41 erreurs sur 210 = 19.5%)

DINOv2 (20 erreurs sur 210 = 9.5%)

| Métrique | ResNet34 (baseline)                                       | DINOv2 (challenger)                      | Analyse                            |
|----------|-----------------------------------------------------------|------------------------------------------|------------------------------------|
| Accuracy | 80%                                                       | 90%                                      | Gain significatif de +10 pts       |
| Erreurs  | Confusions fréquentes (ex: Baby Care <-> Home Furnishing) | Meilleure séparation des classes proches | Meilleure compréhension sémantique |

La confusion Baby Care <-> Home Furnishing persiste pour les deux modèles, suggérant une **similarité visuelle intrinsèque** (couleurs pastel, formes arrondies, matériaux similaires).

## 5. Interprétabilité

- **approche locale (Grad-CAM) :**
  - Pour ResNet : visualisation des cartes d'activation des dernières couches de convolution.
  - Pour DINOv2 : adaptation spécifique, reshape des tokens de patches 1D en grille 2D, exclusion des registres et du token CLS.
  - **constat** : ResNet se concentre souvent sur des textures. DINOv2 cible la forme et l'objet complet, démontrant une compréhension "globale" de l'objet grâce au mécanisme d'attention du ViT.
- **Approche globale :**
  - L'analyse globale peut être réalisée par l'analyse des matrices de confusion, ou en utilisant t-SNE ou UMAP sur les vecteurs de sortie. Cela montre que DINOv2 groupe les images similaires bien mieux que ResNet, ce qui est une preuve visuelle et globale de sa supériorité sémantique.

## 6. Limites

### Interprétabilité

L'interprétabilité n'est pas une simple fonctionnalité logicielle, c'est un domaine de recherche scientifique à part entière appelé **XAI (eXplainable Artificial Intelligence)**.

Définir ce qu'est une bonne explication est difficile. Est-ce une explication fidèle au modèle (faithfulness) ou compréhensible par l'humain (plausibility) ?

Techniquement, cela représente aussi un défi de développement significatif, nécessitant une compréhension fine de l'architecture interne des réseaux pour extraire, transformer et visualiser les gradients d'intérêt via des hooks personnalisés. Les hooks sont des "sondes" pour capter les gradients et les activations pendant la rétropropagation.

### Coût computationnel

Bien que sémantiquement supérieur, DINOv2 (ViT-B/14) impose un coût computationnel considérable par rapport à notre baseline ResNet-34. Par exemple, le mécanisme d'attention oblige chaque patch de l'image à se comparer à tous les autres patches. Même en mode inférence seule, le modèle Transformer est 4 fois plus lourd en mémoire (86M contre 22M de paramètres) et nécessite environ 5 fois plus d'opérations flottantes (17.6 GFLOPs vs 3.6 GFLOPs) pour encoder une seule image.

Le gain de performance se paie par une consommation de ressources multipliée par 5.

## 7. Références

- Oquab et al., "DINOv2: Learning Robust Visual Features without Supervision", arXiv:2304.07193, <https://arxiv.org/abs/2304.07193>
- Darcet et al., "Vision Transformers Need Registers", arXiv:2309.16588, <https://arxiv.org/abs/2309.16588>
- Google Research, "Transformers for Image Recognition at Scale", <https://research.google/blog/transformers-for-image-recognition-at-scale/>.
- Chefer, Transformer-MM-Explainability, <https://github.com/hila-chefer/Transformer-MM-Explainability>
- Gildenblat, vit-explain, <https://jacobgil.github.io/deeplearning/vision-transformer-explainability>